

Red Neuronal

March 17, 2020

1 Red Neuronal

Tutorial de creación de una red neuronal por Alba Reinders Sánchez y Alejandro Valverde Mahou siguiendo el tutorial de [Dot CSV](#)

```
[1]: import numpy as np
import scipy as sc
import matplotlib.pyplot as plt

from sklearn.datasets import make_circles
```

1.1 Problema a resolver

El problema consiste en una clasificación donde los datos están distribuidos de forma circular


1.1.1 Crear el DATASET

```
[2]: n = 500 #número de registros de los datos
p = 2 #número de características de cada dato

X, Y = make_circles(n_samples=n, factor=0.5, noise=0.05) #factor es la
    ↪ distancia entre los círculos

Y = Y[:, np.newaxis]

plt.scatter(X[Y[:, 0] == 0, 0], X[Y[:, 0] == 0, 1], c = "orange")
plt.scatter(X[Y[:, 0] == 1, 0], X[Y[:, 0] == 1, 1], c = "skyblue")
plt.axis("equal")
plt.show()
```



1.1.2 Crear una clase para las capas

Recibirá por parámetro:

1. n_conn : el número de conexiones de la capa
2. n_neur : número de neuronas de la capa
3. act_f : función de activación de la capa

```
[3]: class neural_layer():
    def __init__(self, n_conn, n_neur, act_f):

        self.act_f = act_f
        self.b = np.random.rand(1, n_neur) * 2 - 1 #valor aleatorio entre -1 y 1
        self.W = np.random.rand(n_conn, n_neur) * 2 - 1 #valor aleatorio entre
        ↪ -1 y 1
```

1.1.3 Crear funciones de activación

Función Sigmoides: $\frac{1}{1+e^{-x}}$

Función derivada de Sigmide: $\frac{1}{1-x}$

Función RELU: $\max(0, x)$


```
[4]: #Función sigmoide

sigm = (lambda x: 1 / (1 + np.e ** (-x)),
```

```
lambda x: x * (1-x))

_x = np.linspace(-5, 5, 100)

plt.plot(_x, sigm[0](_x))
plt.show()
```




[5]: *#Función RELU*

```
relu = lambda x: np.maximum(0, x)

_x = np.linspace(-5, 5, 100)

plt.plot(_x, relu(_x))
plt.show()
```



1.2 Crear la Red Neuronal

Compuesta de las distintas **capas**

```
[6]: #capa 0
      #l0 = neural_layer(p, 4, sigm)
      #capa 1
      #l1 = neural_layer(4, 8, sigm)
```

```
[7]: def create_nn(topology, act_f):

      #Estructura de datos para las capas de la red de neuronas
      #Está compuesta por objetos de la clase 'neural_layer'
      nn = []

      #En 'l' se guarda el índice y en 'layer' el valor de 'topology'
      #correspondiente
      for l, layer in enumerate(topology[:-1]):
          nn.append(neural_layer(topology[l], topology[l+1], act_f))

      return nn
```

```
[8]: #Topología de la red de neuronas, número de neuronas por capa
      topology = [p, 4, 8, 16, 8, 4, 1]
      neural_net = create_nn(topology, sigm)
```

1.2.1 Crear la lógica de la red neuronal

Entrenamiento de la red neuronal, consistente en 3 pasos: 1. Procesamiento hacia delante por todas las capas hasta llegar al final y devolver un valor, inicialmente aleatorio en la neurona final. 2. Una vez tiene el resultado, compara con el resultado real o esperado, haciendo uso de la función de coste, y devuelve el error generado para hacer *backpropagation*, una propagación hacia atrás para calcular las derivadas parciales que permite obtener la información necesaria para ejecutar el algoritmo del **Descenso de Gradiente**.

Fórmula de cómputo de error en la última capa: $\delta^L = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L}$

Fórmula de cómputo de error en el resto de capas: $\delta^{l-1} = W^l \delta^l \cdot \frac{\partial a^{l-1}}{\partial z^{l-1}}$

3. El **Descenso de Gradiente** permite optimizar la función de coste y *entrenar* la neurona.

Fórmula de las derivadas de la capa usando el error: $\frac{\partial C}{\partial b^{l-1}} = \delta^{l-1} \quad \frac{\partial C}{\partial w^{l-1}} = \delta^{l-1} a^{l-1}$

Error Cuadrático Medio
$$\frac{\sum_{i=1}^n (Yp_i - Yr_i)^2}{n}$$

Derivada del Error Cuadrático Medio $Yp - Yr$

[9]: *#Función de coste con el error cuadrático medio*

#'Yp' -> 'Y' predicha

#'Yr' -> 'Y' real

```
l2_cost = (lambda Yp, Yr: np.mean((Yp - Yr) ** 2),  
          lambda Yp, Yr: (Yp - Yr))
```

[10]: *#Recibe por parámetro la red neuronal, los valores de entrada, la salida real,*

#la función de coste y el ratio de aprendizaje

#Esta función es la encargada de hacer que la red de neuronas 'aprenda'

```
def train(neural_net, X, Y, l2_cost, lr=0.5, train=True):
```

```
    #'Forward pass' Paso 1
```

```
    out = [(None, X)]
```

```
    for l, layer in enumerate(neural_net):
```

```
        #Calcular la suma ponderada de la capa
```

```
        #'@' hace referencia a la multiplicación matricial
```

```
        #'[-1]' hace referencia al último elemento del array en todo momento
```

```
        z = out[-1][1] @ neural_net[l].W + neural_net[l].b
```

```
        #Salida de la capa
```

```
        a = neural_net[l].act_f[0](z)
```

```
        #Guardar la información del procesamiento de la capa
```

```

out.append((z, a))

if train:
    pass
    #Entrenamiento:
    #'Backward pass' Paso 2 - 'Back-propagation'

    #'delta' hace referencia a las derivadas parciales de cada capas
    #'deltas' es el array con todas las derivadas parciales
    deltas = []

    #Recorrer las capas de la red en orden inverso (empezando por el final)

    for l in reversed(range(0, len(neural_net))):

        #Coger la suma ponderada de la capa y su salida correspondiente
        z = out[l+1][0]
        a = out[l+1][1]

        #Última capa
        if l == len(neural_net) - 1:
            #Calcular delta de la última capa

            #Queremos insertar cada capa delante de la anterior, por eso se
            #insertan siempre en la posición 0, de forma que la última capa
            #insertada aparezca la primera

            #Fórmula de cómputo de error en la última capa

            #se calcula la derivada de la función de coste aportando la
            #salida de la capa y el resultado real y se multiplica por la
            #derivada de la función de activación a la que se le pasa
            #la salida de la capa
            deltas.insert(0, l2_cost[1](a, Y) * neural_net[l].act_f[1](a))

        else:
            #Calcular delta respecto a la capa previa
            deltas.insert(0, deltas[0] @ _W.T * neural_net[l].act_f[1](a))

        _W = neural_net[l].W

        #'Gradient descent' paso 3

        neural_net[l].b = neural_net[l].b - np.mean(deltas[0], axis=0,
→keepdims=True) * lr
        neural_net[l].W = neural_net[l].W - out[l][1].T @ deltas[0] * lr

```

```
return out[-1][1]
```

```
[11]: # VISUALIZACIÓN Y TEST
```

```
import time
from IPython.display import clear_output

topology = [p, 4, 8, 1]

neural_n = create_nn(topology, sigm)

loss = []

for i in range(2000):

    # Entrenemos a la red!
    pY = train(neural_n, X, Y, l2_cost, lr=0.05)

    if i % 25 == 0:

        print(pY)

        loss.append(l2_cost[0](pY, Y))

        res = 50

        _x0 = np.linspace(-1.5, 1.5, res)
        _x1 = np.linspace(-1.5, 1.5, res)

        _Y = np.zeros((res, res))

        for i0, x0 in enumerate(_x0):
            for i1, x1 in enumerate(_x1):
                _Y[i0, i1] = train(neural_n, np.array([[x0, x1]]), Y, l2_cost,
→train=False)[0][0]

        plt.pcolormesh(_x0, _x1, _Y, cmap="coolwarm")
        plt.axis("equal")

        plt.scatter(X[Y[:,0] == 0, 0], X[Y[:,0] == 0, 1], c="orange")
        plt.scatter(X[Y[:,0] == 1, 0], X[Y[:,0] == 1, 1], c="skyblue")

        clear_output(wait=True)
        plt.show()
        plt.plot(range(len(loss)), loss)
        plt.show()
        time.sleep(0.5)
```

